אור קוסטה
204022487

APML EX3

שאלה 2.4

תוצאות המודל הלינארי:

ה loss של הטסט

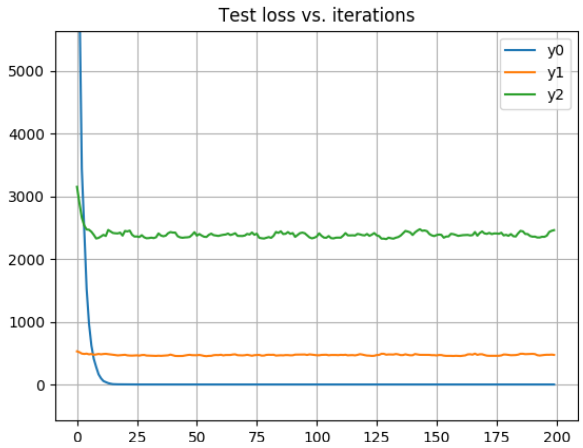

תוצאות ה convnet :

תחילה ניתן לראות שהמודל הלינארי לא הצליח להתכנס לתוצאה יפה עבור הפונק' y1, y2. בנוסף אפשר לראות כי עבור הפונקציות הנ"ל גרף השגיאה נותר יציב, רצינו לקרב את המודל הלינארי לפונקציות אבל הפונקציות 1,2 אינן לינאריות לכן הצליח המודל להתקרב אליהן ממש מעט (ניתן לראות ירידה קטנה בהתחלה) אך כיוון שהמודל לינארי נשארת תמיד שגיאה של קירוב בין גרף הפונקציה שהוא מתאר לגרף של הפונקציות 1,2 (אם רוצים לחשוב על הבעיה בצורה גאומטרית, קירוב של גרף קעור בעזרת קווים ישרים).

לגבי y0 הפונקציה עצמה לינארית ולכן למודל היה קל ללמוד אותה עד כדי מזעור השגיאה כמעט לחלוטין.

כלומר המודל כן מדויק ועובד טוב, השאלה היא איזה פונ' רוצים ללמוד בעזרתו.

לעומת זאת, הconvnet יכולה להגדיר משפחה גדולה יותר של פונקציות בעזרת השכבות, בפרט פונקציות שאינן ליניאריות כיוון שיש לנו גם פונ' max וגם פונ' relu שאינן ליניאריות. ואכן ניתן לראות שמשפחת הפונ' לא לינארית על ידי התבוננות על הגרף של y0 שהיא פונ' לינארית. הרשת הגיעה לנק' בה היא לא יכולה לצמצם יותר את השגיאה שוב אפשר לחשוב על זה גאומטרית כקירוב של גרף קעור לייצוג של גרף ישר.

בנוסף ניתן לראות כי הפונ' 1,2 הגיעו לשגיאה נמוכה, כפונ' שאינן ליניאריות.

שאלה 2.5

המודל הלינארי:

תוצאה סופית : score : [0.2688840436562896, 0.9239999979734421]

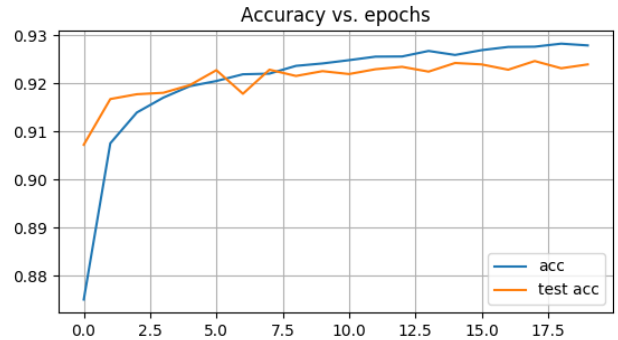

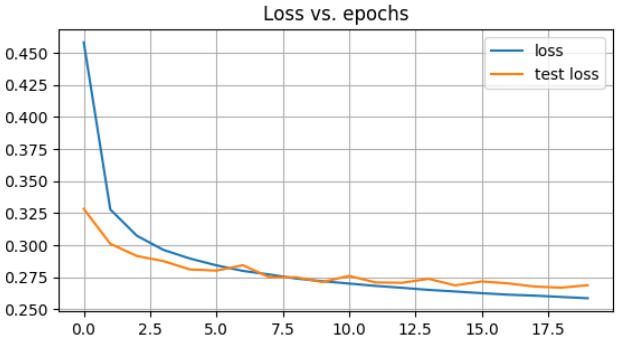

ניתן לראות שהגענו לתוצאה יחסית טובה

עבור שכבת FC אחת.

אפשר לראות שהמודל מצליח להתקרב

לסט האימון אך אינו יציב בטסט לחלוטין

מה שמראה שהלמידה לא מספיק מדוייקת.

מודל הMLP :

תחילה הוספתי למודל הקודם שכבה נוספת בגודל 10 עם relu וקיבלתי את התוצאה :

score : [0.22259172247955575, 0.9364999988675118]

בבדיקה על העמקת המודל ראיתי שהתוצאה הסופית כמעט ולא משתנה מעומק של יותר מ4 שכבות. לבסוף בחרתי מודל עם 3 שכבות FC בנוסף לאקטיבצית relu. כל שכבה קטנה יותר מקודמתה, בעיקר משיקול של זמני ריצה (כמות משקולות קטנה יותר).

בחישוב הloss בחרתי ב - categorical_crossentropy שהיא פונקציה המתאימה למודל שלי שמוציא וקטור הסתברויות אל מול הטסט שהוא וקטור אפסים עם 1 במקום התיוג הנכון. בקצרה, הפונ' הנ"ל סוכמת את לוג ההסתברויות כפול הערכים באינדקסים המקבילים בטסט כלומר במקרה שלנו פשוט לוג של הערך באינדקס שמספרו מופיע בתמונה. כלומר אם בהסתברות 1 זה אכן התיוג הנכון => לוג 1 יוצא 0 => loss=0

הגרף שהתקבל:

ביחד עם התוצאה :

score : [0.06610373745325603, 0.9823000019788742]

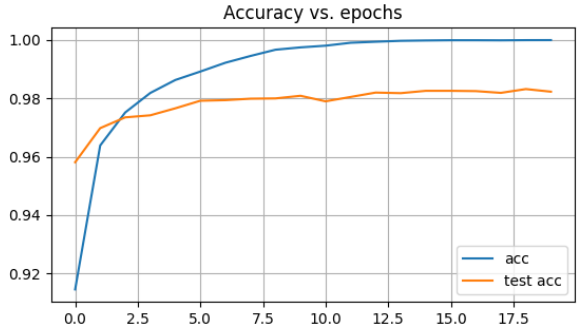

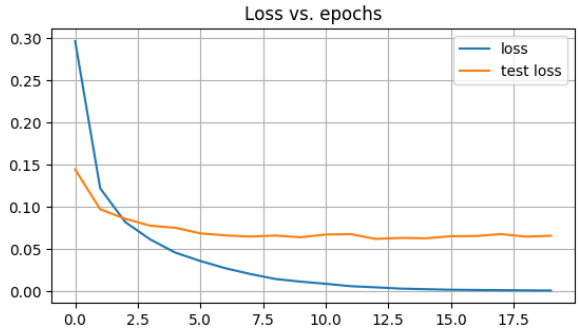

מודל ה Convnet :

גם במודל הזה בחרתי בloss של : categorical_crossentropy, הפלט של המודל והlabels של האימון נשארו זהים כמו במודלים האחרים לכן אין סיבה לשנות את חישוב הloss שמתאים מאותם שיקולים שהסברתי קודם.

את המודל עצמו בניתי משתי שכבות קונב' בניהן שתי שכבות max-pooling ולבסוף FC לפני ה output הסופי.

משחק עם השכבות מבחינת גדלים ועומק הקרנלים לא משנה כמעט את התוצאה למעט הכבדה על זמני הריצה במודלים עמוקים יותר.

התוצאות :

score: [0.04767881222032884, 0.9847000008821487]

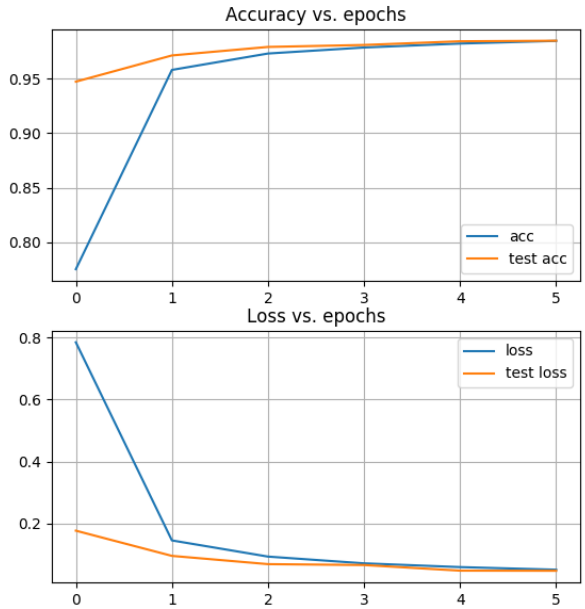

לסיכום:

ניתן לראות שהוספת שכבה אחת + relu הוסיפו מורכבות ואי ליניאריות שהעלתה לנו את הדיוק מ 92 ל98 ופה הייתה בעיקר הקפיצה העיקרית.

במודל הקונב' הוספנו אפילו עוד מורכבות והגדלנו את משפחת הפונקציות שהרשת מסוגלת לתאר, אימנתי על 6 epochs עם batchSize=500

והגעתי לדיוק טיפה יותר גבוהה ברשת הקונב' אפשר גם לראות שיש מעט overfit במודל הMLP שלא נראה במודל הקונב' מה שנותן עוד מדד לכך שהלמידה של המודל הזה טובה יותר. בהסתמך על הכמות הקטנה יחסית של איטרציות הלמידה אפשר להסיק כי מודל הקונב' טוב יותר. מה שמתיישב עם מה שלמדנו כי רשתות אלה עובדות טוב יותר על דאטא של תמונות.

חקירת היפר פרמטר :

בחרתי בפרמטר dropout עבור מודל הMLP בתקווה לראות השפעה על הoverfit של הגרף שקיבלתי ושינויים כללים בגרף הלמידה. הוספתי שתי שכבות dropout בין שכבות הFC ונתתי להם פרמטר זהה.

בדקתי הורדה של 10, 30, 60 ו90 אחוז מהמשקולות במודל.

הגרפים שקיבלתי:

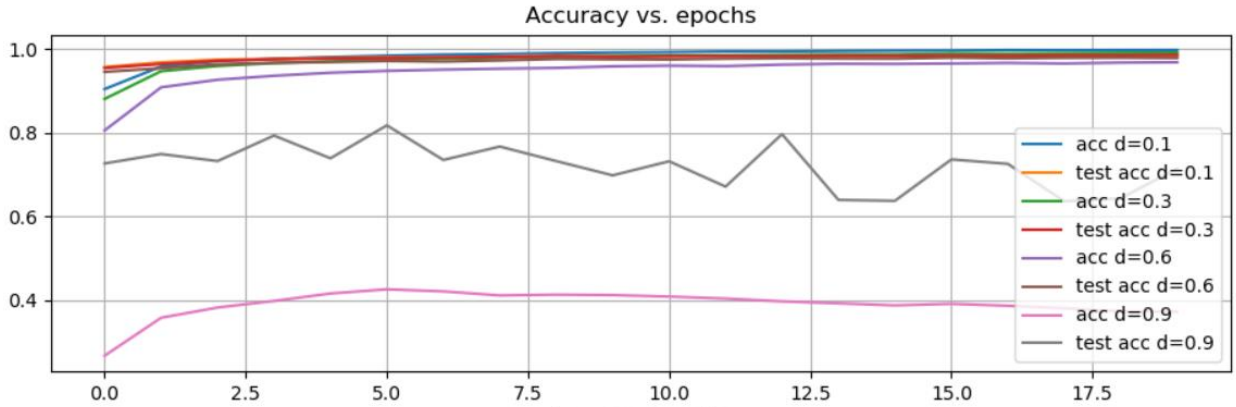

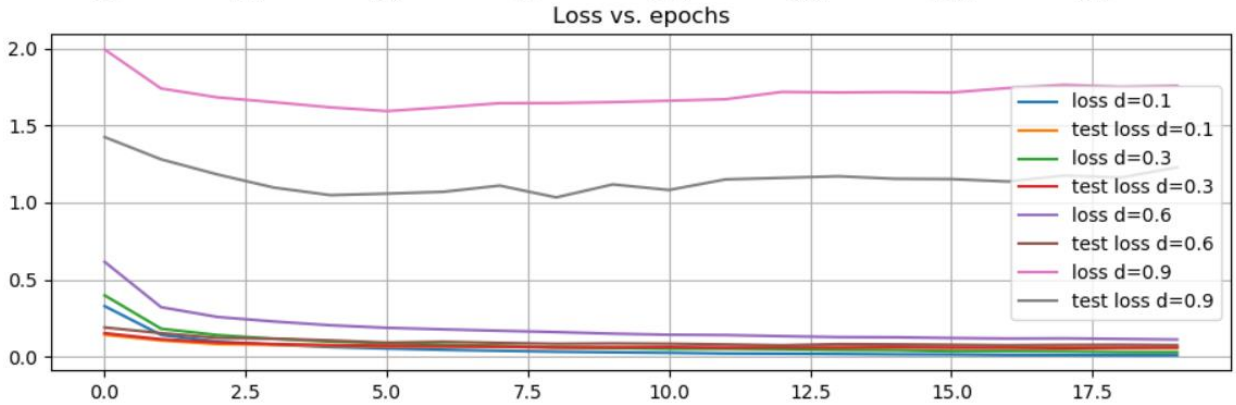


```
0.1 : score : [0.059138250551443436, 0.9839000016450882]
0.3 : score : [0.0601337310825096, 0.9851000037789345]
0.6 : score : [0.0755119291957817, 0.9779000017046928]
0.9 : score : [1.2289287286996842, 0.7137000025808811]
```

ניתן לראות בגדול שהורדה של 10 אחוז מהמשקולות לא השפיעה בהרבה, ניתן לראות אבל שהפחתה של 0.3 העלתה את הדיוק מהמודל המקורי. בהפחתה של 60 אחוז מהמשקולות התחילה כבר ירידה בדיוק וב90 כמצופה איבדנו דיוק משמעותי.

אפשר לראות שבגרף המקורי הייתה תופעה של overfitting, הגרף של האימון הגיע ל100 אחוז דיוק בעוד גרף הטסט נשאר ללא שינוי. דבר זה מעיד בעיקר על יתר מורכבות של הרשת. קירבתי את הגרפים באזור ההתכנסות הסופי וזה נראה כך:

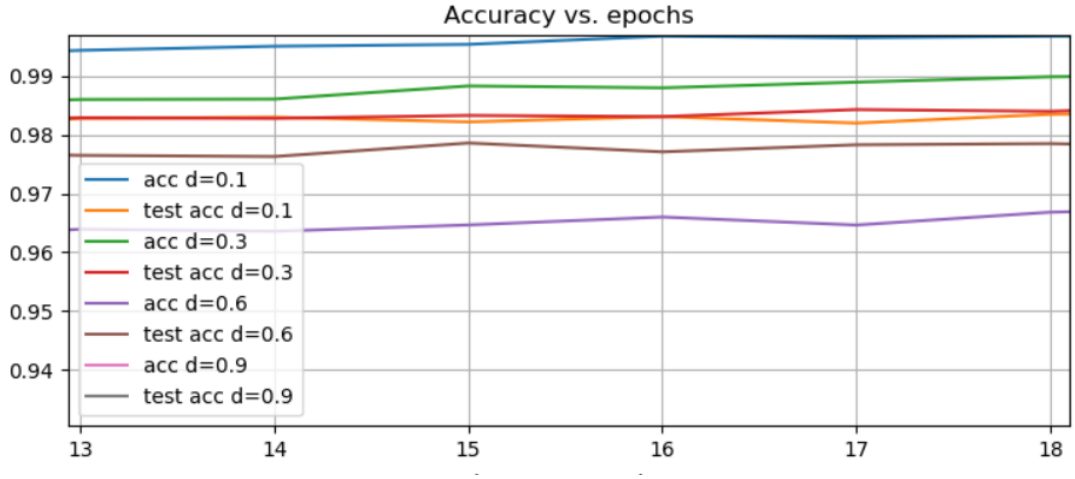

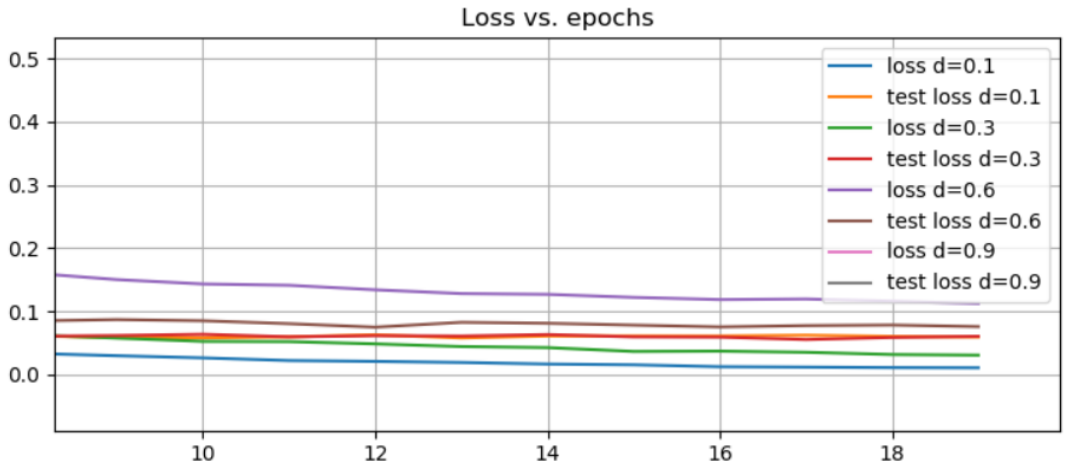

כפי שציפיתי לראות עבור 30 אחוז הפחתה (המודל שהגיע לדיוק הטוב ביותר) ניתן לראות את הגרפים של האימון ושל הטסט הכי קרובים מה שמעיד על למידה טובה ומדוייקת יותר מהמודל המקורי.

לסיכום, שכבת הdropout נועדה להפחתת מורכבות המודל על מנת להשיג תוצרי למידה טובים יותר ואכן ראינו שזה נכון בניסוי הקטן שערכנו.

שאלה 2.6

התחלתי בבניית המודל הנאיבי ביותר, שתי שכבות FC שמצמצמות מ 784 ל2 וחזרה ל784, על המודל הזה השוותי שני optimizers שאני מכיר שהם הSGD שהשתמשתי במודלים הקודמים וAdam שגם הוא מתבסס על רעיון דומה. נוכחתי לראות שAdam השיג loss טוב יותר אז נשארתי איתו.

עברתי לעבוד על מורכבות הרשת, הוספתי עוד כמה שכבות FC וראיתי שיש לכך השפעה לטובה על הloss, בדקתי את ההשפעה של הrelu על הloss וראיתי שהוספה של אקטיבציה כזאת עוזרת גם כן להפחית בloss. בשלב זה החלטתי לשנות ארכיטקטורה ולבדוק את רשת הקונב', הסתמכתי על מבנה דומה ל convent מהסעיף הקודם, לא ראיתי השפעה גדולה יותר מידי וסה"כ שני המודלים הגיעו לתוצאות דומות. החלטתי להישאר עם מודל הFC בעיקר כי הייתי יותר בטוח באופן הבנייה שלו. 8 שכבות FC שמתכנסות למימד 2 באמצע וחוזרות בהדרגה ל 784 בפלט.

גרף ה loss :

מתכנס לערך

של 0.034 על הטסט.

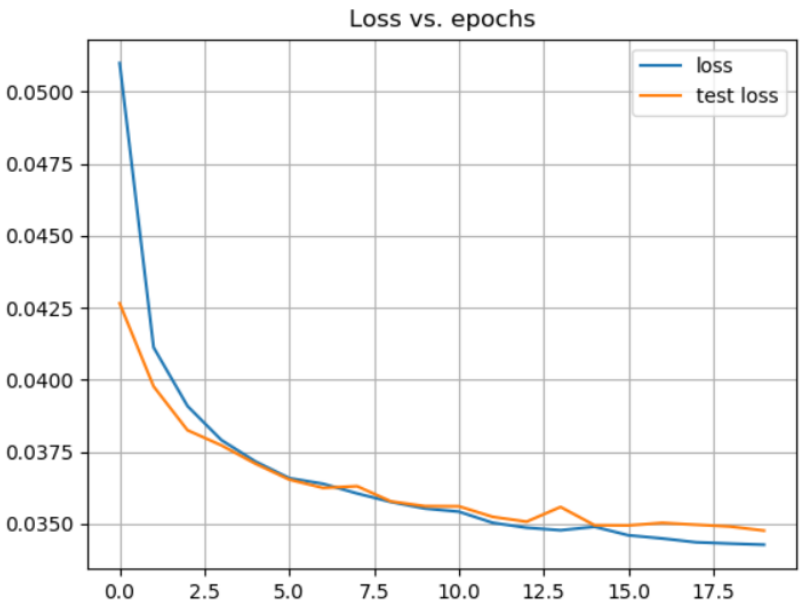

מודל הPCA:

כפי שהתבקש הרצתי את המודל לצמצום של 5000 דגימות להלן:

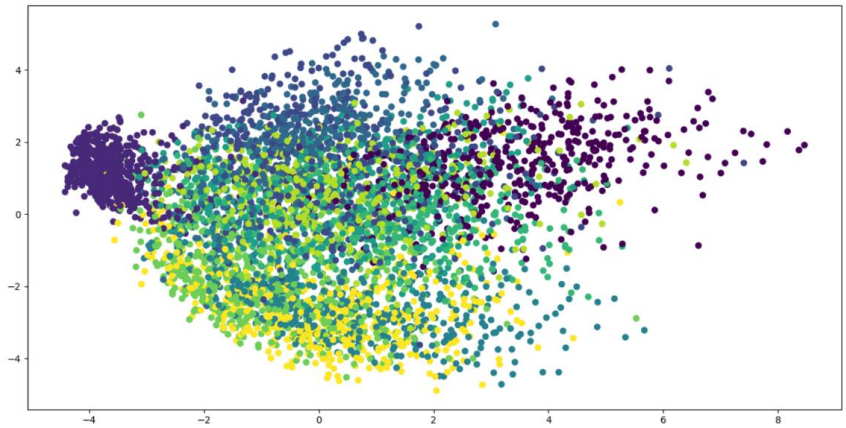

ניתן לראות חלוקה מסויימת לאזורים.

המודל שלי:

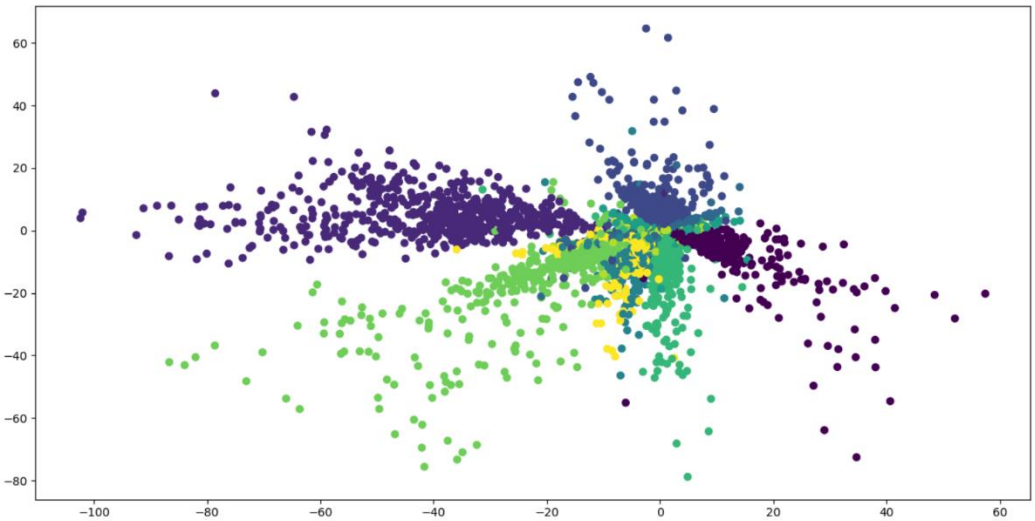

ניתן לראות במודל שלי חלוקה מסודרת יותר במרחב לפי התיוגים, סה"כ כמצופה שוב מהיכולת של הרשת לבנות מודל מורכב יותר, למרות שהשתמשתי בשכבות ליניאריות אך ה relu מכניס גם גורם אי ליניאריות למשוואה.

רציתי לנסות להפעיל אקטיבציה על השכבה האמצעית של ה2, הוספתי relu וחזרתי על התהליך, הloss הכללי היה זהה אך במרחב זה נראה עכשיו כך: